Национальный исследовательский университет
«Высшая школа экономики»
Лицей

Индивидуальная выпускная работа

Отчет о проекте

Альфа Защита

Выполнил Харченко Богдан Никитич
Группа 11и2

Москва 2026

Оглавление

Введение....3
Проблемное поле....3
Целевая аудитория....3
Функциональные требования....4
Используемый стек технологий....6
Этапы работы над проектом....6
Краткий анализ аналогичных продуктов....7
Рефлексия....8
    Проблемы и решения....8
    Приобретенные навыки....9
    Альтернативные пути....10
    Дальнейшее развитие....10
Источники....10
Отзывы представителей целевой аудитории....11

Введение

«Альфа Защита» — веб-сервис для проверки подозрительных сообщений, ссылок, QR-кодов, скриншотов переписки и обстоятельств предполагаемого перевода. Пользователь получает объяснение обнаруженных признаков и рекомендации, что стоит перепроверить перед действием.

Меня заинтересовала возможность применить машинное обучение к ситуации, в которой человеку нужен конкретный сигнал для перепроверки просьбы, а не только общая оценка риска.

Создано приложение с девятью функциями, гостевым режимом и личной историей. Продукт размещен на сервере; исходный код и сценарии собраны в репозитории проекта [1].

Проблемное поле

По сообщению не всегда понятно, действительно ли человеку пишет знакомый, сотрудник организации или мошенник. Просьба перевести деньги может выглядеть правдоподобно, а подозрительная ссылка — почти не отличаться от привычного адреса. При этом собеседник может торопить пользователя, пугать последствиями или требовать сохранить разговор в тайне.

В условиях эмоционального напряжения и давления отдельная деталь может остаться незамеченной. Конкретное предупреждение о просьбе сообщить код, смене реквизитов или несоответствии адреса ожидаемому банку может стать поводом сделать паузу и задать вопрос: «Не пытаются ли меня обмануть?».

Задача проекта — помочь пользователю вовремя заметить такое основание и самостоятельно перепроверить просьбу. Отсутствие найденных признаков не подтверждает безопасность. Сервис не принимает решение за человека, не подключается к его банковскому счету и не выполняет платежи.

Целевая аудитория

Проект ориентирован на русскоязычных пользователей в РФ, совершающих платежи в рублях: подростков с небольшим опытом

самостоятельных переводов, пожилых пользователей с ограниченным опытом цифровых сервисов и взрослых, редко совершающих онлайн-платежи. Учитывается опыт человека, а не только возраст.

Потенциальным заказчиком может выступить Альфа-Банк. Проект разрабатывается как самостоятельный учебный сервис; подтвержденное сотрудничество с банком не заявляется. Проверка понятности предупреждений представителями целевой аудитории остается отдельной задачей. Для их отзывов предусмотрено приложение к отчету.

Функциональные требования

Сервис работает в браузере компьютера или смартфона. Для обращения к нему требуется интернет; установка отдельного приложения не нужна. Реализованы следующие функции.

1. **Аккаунт.** Пользователь регистрируется по логину и паролю, входит в аккаунт и получает доступ к своим данным. После выхода для открытия личной истории требуется повторный вход. Данные доступны в другой сессии браузера после авторизации.

2. **Проверка текста.** Пользователь вставляет сообщение и отправляет его на анализ. Система ищет признаки подозрительных просьб, показывает обнаруженные основания и рекомендации. В гостевом режиме результат доступен на текущей странице и не записывается в личную историю.

3. **Проверка ссылки.** Пользователь вводит URL и при необходимости указывает ожидаемую организацию. Система анализирует адрес, сопоставляет его с известными официальными доменами и объясняет найденные несоответствия. Переход на проверяемый сайт не выполняется.

4. **Проверка QR-кода.** Пользователь загружает изображение с одним QR-кодом. Сервис извлекает HTTP(S)-ссылку, показывает ее и передает анализатору URL. Нечитаемые коды и неподдерживаемое содержимое отклоняются с объяснением.

5. **Проверка скриншота.** Пользователь загружает PNG или JPEG с перепиской. Система распознает текст и анализирует содержащиеся в нем просьбы. Пользователь может сопоставить распознанный текст с изображением и прочитать основания результата. Подлинность скриншота не устанавливается.

6. **Проверка перевода.** Пользователь указывает сумму, назначение, доступные сведения о получателе и обстоятельства обращения. Система объединяет ответы анкеты с анализом оригинальной просьбы и личной историей. Положительный ответ пользователя не отменяется моделью. Статистика помогает отметить нетипичную сумму и отсутствие получателя в доступной истории; эти признаки не означают доказанного мошенничества.

7. **Импорт истории.** После входа пользователь загружает CSV по шаблону или вводит операции строками. Новые строки добавляются к истории; полная замена выполняется по отдельному выбору. До сохранения проверяется весь ввод. Ошибка не меняет прежние данные.

8. **История проверок.** Пользователь открывает список своих результатов и выбирает нужную проверку. Сохраненный ответ содержит дату и версию анализатора. Последующее изменение истории операций или отзыва не переписывает исходный вывод.

9. **Обратная связь.** Пользователь сообщает исход сохраненной проверки: мошенничество, обычная ситуация или неизвестно; при необходимости добавляет комментарий. Отзыв можно исправить. Согласие на подготовку данных для будущего обучения сохраняется отдельно и может быть отозвано. Автоматического дообучения нет.

Для демонстрации подготовлены вымышленные сообщения, изображения и история операций. Они позволяют пройти сценарии без настоящих персональных данных. Порядок показа и конкретные значения полей описаны в файле пользовательских сценариев [1].

Используемый стек технологий

Основной язык проекта — Python. Django предоставляет механизмы форм, аккаунтов и работы с базой данных, сокращая вспомогательный код. Интерфейс создается средствами Django Templates, HTML, CSS и JavaScript.

PostgreSQL хранит пользователей, операции, результаты, отзывы и согласия. Одна СУБД используется при разработке, тестировании и размещении, чтобы проверять запросы и ограничения до установки на сервер.

Для текста используются PyTorch, Transformers и дообученный rubert-tiny2. Модель выделяет семь признаков: срочность, просьбу о деньгах, запрос секретных данных, секретность, установку программы или доступ, представление сотрудником и «защитный» перевод. URL анализирует символьная сверточная сеть. Общий ответ формируют явные правила с учетом анкеты и статистики операций.

EasyOCR извлекает текст скриншотов, OpenCV декодирует QR. Собственная часть проекта включает обучение анализаторов текста и URL, подготовку данных, правила объединения сигналов, статистику истории и веб-сценарии.

Зависимости фиксируются через uv и lock-файл. Тесты pytest и pytest-django запускаются GitHub Actions. Для размещения используются Docker Compose, Gunicorn и Nginx; модели загружаются из локальных файлов.

Этапы работы над проектом

Тема «Альфа Защиты» сохранилась; менялись архитектура, методы анализа и состав проверок.

Июнь–август 2026 года. Сформирован первоначальный образ продукта и частично реализована ранняя версия. Были подготовлены первые компоненты и накоплен опыт работы с выбранными сценариями.

Сентябрь. При расширении набора проверок выявились ограничения первоначальной структуры. Было принято решение переработать архитектуру, сохранив полезные наработки и пользовательские сценарии.

Сентябрь — 25 октября. Уточнялись требования, структура данных и способы взаимодействия компонентов. Для новой версии выбраны Django и PostgreSQL, подготовлен переход прежнего функционала на новую основу.

26–31 октября. Выполнялись перенос и адаптация логики аккаунтов, форм, хранения результатов, CSV и обратной связи. Были добавлены автоматические проверки.

1–4 ноября. Проводились эксперименты с текстовыми и URL-моделями, подключались статистика операций, общий анализатор, интерфейс и объяснения результатов.

5 ноября. Подключены выбранные модели, аудиоввод заменен проверкой QR-кода, доработан ручной ввод истории. Проверены пользовательские сценарии и размещение, подготовлены итоговые документы и демонстрационные примеры.

Краткий анализ аналогичных продуктов

Bitdefender Scamio анализирует сообщения, ссылки, изображения и QR-коды и дает рекомендации [2]. Это близкий аналог проверки обращений. В его описании не выделен отдельный процесс импорта личной истории операций и сравнения с ней предстоящего перевода.

Norton Genie / Scam Protection позволяет передать текст, сайт или изображение для проверки подозрительной ситуации [3]. Описанный сценарий сосредоточен на содержании обращения; персональная статистика суммы и сопоставление получателя с импортированной историей в нем не представлены.

VirusTotal объединяет результаты технических проверок файлов и URL [4]. Такой отчет полезен для анализа ссылки, но сам по себе не разбирает давление собеседника и обстоятельства перевода. Подозрительная просьба может вообще не содержать файлов или ссылок.

Акцент моего проекта — совместное использование текста просьбы, ответов пользователя и его истории операций. Например, смена реквизитов рассматривается вместе с нетипичной суммой или отсутствием получателя в

истории. Пользователь получает объяснение конкретного сочетания признаков. Более высокая точность по сравнению с перечисленными продуктами не заявляется.

Рефлексия

Проблемы и решения

Главной трудностью оказалась нехватка подходящих данных. Для проекта требовалась русскоязычная разметка отдельных признаков: срочности, секретности, просьбы сообщить код и других действий. Общая метка «спам» или «мошенничество» не заменяет такую разметку. Один и тот же признак может встречаться в обычной ситуации, поэтому важны содержание просьбы и ее контекст.

Для текстовых экспериментов был подготовлен синтетический корпус из 10 000 строк. Связанные примеры разделялись по семействам между обучением и проверкой. Это снижает риск попадания близких вариантов в разные части, но не устраняет общий недостаток синтетики: повторяющиеся формулировки и ограниченное разнообразие ситуаций. Автоматическая разметка также может ошибаться. Поэтому результаты на этом корпусе нельзя считать доказательством качества на произвольной реальной переписке.

Отдельная проблема обнаружилась у URL-модели. Архивный набор PhiUSIIL [5] отличается от адресов, которые пользователь вводит на сайте. В частности, обычные ссылки с путями вызывали лишние предупреждения. В текущей версии изменена подготовка входа: модель получает схему и имя узла, а полный адрес остается для объяснений и проверок структуры. Это уменьшило ложные срабатывания в контрольном наборе, но снизило полноту на архивных данных. Решение является компромиссом и требует дальнейшей проверки на свежих ссылках.

Для итогового предупреждения я выбрал явные правила вместо еще одной обучаемой модели. Так можно показать конкретное сочетание оснований и не выдавать неподтвержденную вероятность мошенничества. Статистика суммы

также рассматривается только как отклонение от личной истории. Недостаточные данные не заменяются предположением об отсутствии риска.

При выборе порогов приоритет отдается обнаружению подозрительных признаков. Однако большое число лишних предупреждений тоже ухудшает полезность сервиса. Нужны отдельный разбор пропусков и ложных срабатываний, а также проверка того, понимает ли пользователь объяснение. Сбор отзывов создает материал для такого разбора, но сам по себе не улучшает модель: нужны согласие, проверка исходов и отдельное обучение.

Аудиоввод оказался слишком затратным для выбранного сценария. В локальной Linux-эмуляции обработка минутной записи занимала несколько минут; значительную часть времени требовало разделение голосов. Это плохо соответствовало задаче дать своевременный сигнал перед действием. Аудио заменено QR-кодом, для которого используется уже существующий анализатор ссылок. Распознавание скриншотов также может ошибаться, поэтому извлеченный текст доступен пользователю для проверки.

Работу сайта и качество моделей пришлось проверять отдельно. Проверки аккаунтов, импорта, сохранения результатов и размещения показывают, что пользовательский сценарий выполняется, но не доказывают правильность каждого предупреждения. Время обработки в эмуляции также нельзя напрямую переносить на сервер. Эта разница стала важным выводом работы.

Приобретенные навыки

Я разобрался с Django, формами, сессиями, миграциями и доступом к данным. Пришлось согласовать загрузку файлов и обработку ошибок, чтобы некорректный ввод не приводил к потере истории.

В машинном обучении я работал с многометочной классификацией, разметкой, разбиением связанных примеров и порогами. На практике стало понятно, почему высокая метрика на удобном наборе еще не означает устойчивую работу сервиса.

Также я освоил автоматические тесты, фиксацию зависимостей, сборку контейнеров и размещение приложения с базой данных.

Альтернативные пути

Я бы раньше определил, какие данные нужны для каждой проверки и какой результат считать приемлемым. Небольшой независимый набор реальных примеров помог бы обнаружить ограничения до усложнения моделей и интерфейса.

Медиаобработку также стоило проверить в начале работы: сначала измерить время и ошибки распознавания, затем включать ее в обязательный объем. Это позволило бы раньше отказаться от аудиосценария. Проверку понятности предупреждений представителями аудитории следовало начать параллельно с прототипом; эта часть еще требует завершения.

Дальнейшее развитие

Основное направление — сбор разнообразных русскоязычных примеров с проверенной разметкой и согласованным использованием данных. На таком материале можно повторно оценить пороги и сравнить модели на независимых случаях. Историю отзывов следует использовать только после проверки: сообщенный пользователем исход может быть неполным или ошибочным.

Также можно улучшить распознавание переписок разных мессенджеров, поддержку банковских выписок и удобство обозначения получателей. Следующий этап пользовательской оценки должен показать, какие объяснения помогают человеку перепроверить просьбу, а какие остаются непонятными. Возвращение аудио имеет смысл рассматривать после проверки приемлемой задержки и качества распознавания.

Источники

1. Репозиторий проекта Альфа Защита и пользовательские сценарии.

2. Bitdefender Scamio. Официальное описание.

3. Norton Scam Protection. Официальное описание возможностей.

4. VirusTotal. How it works.

5. UCI Machine Learning Repository. PhiUSIIL Phishing URL Dataset.

Отзывы представителей целевой аудитории

Имя автора отзыва: _____

Дата: _____

Какие сценарии проверены: _____

Отзыв о понятности результата и удобстве работы:

_____

_____

_____

_____

_____

_____