Национальный исследовательский университет
«Высшая школа экономики»
Лицей

Индивидуальная выпускная работа

Отчет о проекте

Альфа Защита

Выполнил Харченко Богдан Никитич
Группа 11и2

Москва 2026

Оглавление

Введение....3
Проблемное поле....3
Целевая аудитория....3
Функциональные требования....4
Используемый стек технологий....4
Этапы работы над проектом....5
Краткий анализ аналогичных продуктов....6
Рефлексия....6
Проблемы и решения....6
Приобретенные навыки....7
Альтернативные пути....8
Дальнейшее развитие....8
Источники....8

Введение

«Альфа Защита» — веб-сервис для проверки подозрительных сообщений, ссылок, QR-кодов, скриншотов переписки и обстоятельств предполагаемого перевода. Пользователь получает объяснение обнаруженных признаков и рекомендации, что стоит перепроверить перед действием.

Я хотел применить машинное обучение, чтобы помогать людям замечать подозрительные просьбы и понимать, что именно стоит перепроверить.

Создано приложение с девятью функциями, гостевым режимом и личной историей. Домен проекта: https://alphadefense.ru. Рабочий адрес: https://91.197.98.216/. Исходный код: https://github.com/dzprht/alphago1v.

Проблемное поле

По сообщению не всегда понятно, действительно ли человеку пишет знакомый, сотрудник организации или мошенник. Просьба перевести деньги может выглядеть правдоподобно, а подозрительная ссылка — почти не отличаться от привычного адреса. При этом собеседник может торопить пользователя, пугать последствиями или требовать сохранить разговор в тайне.

Под давлением легко не заметить просьбу сообщить код или несоответствие адреса ожидаемому банку.

Задача проекта — показать подозрительные признаки и помочь перепроверить просьбу до перевода денег или передачи личных сведений. Отсутствие предупреждения не гарантирует безопасность.

Приоритет — не пропустить опасную просьбу: лучше лишний раз предупредить.

Целевая аудитория

Проект ориентирован на русскоязычных пользователей в РФ, совершающих платежи в рублях: подростков с небольшим опытом самостоятельных переводов, пожилых пользователей с ограниченным опытом цифровых сервисов и взрослых, редко совершающих онлайн-платежи.

Функциональные требования

Сервис работает в браузере компьютера или смартфона. Разовые проверки доступны без регистрации; аккаунт нужен для сохранения результатов, загрузки операций и отзывов.

1. Аккаунт. Регистрация, вход и доступ к своим данным с другого устройства.

2. Проверка текста. Пользователь вставляет сообщение и получает объяснение найденных признаков и рекомендации.

3. Проверка ссылки. Сервис анализирует адрес и сравнивает его с официальными доменами ожидаемой организации, если она указана.

4. Проверка QR-кода. Сервис извлекает одну HTTP(S)-ссылку из изображения, показывает адрес и результат его проверки.

5. Проверка скриншота. Сервис распознает переписку в PNG или JPEG и проверяет ее текст. Распознанный текст можно посмотреть вместе с результатом.

6. Проверка перевода. Сервис учитывает сумму, получателя, ответы анкеты и оригинальную просьбу о переводе. При наличии личной истории отмечает нетипичную сумму и получателя, которого нет в загруженной истории.

7. Импорт истории. Пользователь загружает CSV по шаблону или вводит операции вручную. Можно дополнить историю или заменить ее целиком.

8. История проверок. Пользователь открывает список своих результатов и выбирает нужную проверку.

9. Обратная связь. Пользователь указывает исход ситуации и оставляет комментарий к проверке. Отдельно можно разрешить использование данных для будущего обучения и позже отозвать согласие.

Используемый стек технологий

Основной язык проекта — Python. Django предоставляет механизмы форм, аккаунтов и работы с базой данных, сокращая вспомогательный код. Интерфейс создается средствами Django Templates, HTML, CSS и JavaScript.

PostgreSQL хранит пользователей, операции, результаты, отзывы и согласия.

Для текста используются PyTorch, Transformers и дообученный rubert-tiny2. Модель выделяет семь признаков: срочность, просьбу о деньгах, запрос секретных данных, секретность, установку программы или доступ, представление сотрудником и «защитный» перевод. URL анализирует символьная сверточная сеть. Общий ответ формируют явные правила с учетом анкеты и статистики операций.

EasyOCR извлекает текст скриншотов, OpenCV декодирует QR. Собственная часть проекта включает обучение анализаторов текста и URL, подготовку данных, правила объединения сигналов, статистику истории и веб-сценарии.

Зависимости фиксируются через uv и lock-файл. Тесты pytest и pytest-django запускаются GitHub Actions. Для размещения используются Docker Compose, Gunicorn и Nginx.

Этапы работы над проектом

Тема «Альфа Защиты» сохранилась; менялись архитектура, методы анализа и состав проверок.

Июнь–август 2026 года. Сформирован первоначальный образ продукта и частично реализована ранняя версия. Были подготовлены первые компоненты и накоплен опыт работы с выбранными сценариями.

Сентябрь. При расширении набора проверок выявились ограничения первоначальной структуры. Было принято решение переработать архитектуру, сохранив полезные наработки и пользовательские сценарии.

Сентябрь — 25 октября. Уточнялись требования, структура данных и способы взаимодействия компонентов. Для новой версии выбраны Django и PostgreSQL, подготовлен переход прежнего функционала на новую основу.

26–31 октября. Выполнялись перенос и адаптация логики аккаунтов, форм, хранения результатов, CSV и обратной связи. Были добавлены автоматические проверки.

1–4 ноября. Проводились эксперименты с текстовыми и URL-моделями, подключались статистика операций, общий анализатор, интерфейс и объяснения результатов.

5 ноября. Подключены выбранные модели, аудиоввод заменен проверкой QR-кода, доработан ручной ввод истории. Проверены пользовательские сценарии и размещение, подготовлены итоговые документы и демонстрационные примеры.

Краткий анализ аналогичных продуктов

Bitdefender Scamio анализирует сообщения, ссылки, изображения и QR-коды и дает рекомендации [1]. В официальном описании нет проверки перевода по личной истории операций.

Norton Genie / Scam Protection позволяет передать текст, сайт или изображение для проверки подозрительной ситуации [2]. В описании этого сценария не заявлено сопоставление суммы и получателя с загруженной пользователем историей операций.

VirusTotal объединяет результаты проверок файлов и URL [3]. Он помогает проверить ссылку, но не разбирает просьбу о переводе и давление собеседника.

Наше основное отличие — проверка предполагаемого перевода с учетом личной истории операций. Сервис отмечает нетипичную сумму и получателя, которого нет в загруженной истории, и учитывает эти признаки вместе с текстом просьбы и ответами анкеты. Для ссылки учитываются сам адрес, сопровождающее сообщение и ожидаемая организация.

Рефлексия

Проблемы и решения

Главной трудностью оказалась нехватка подходящих данных. Нужна была русскоязычная разметка отдельных признаков: срочности, секретности, просьбы сообщить код и других действий. Общей метки «спам» или «мошенничество» для этого недостаточно.

Для текстовых экспериментов подготовлен синтетический корпус из 10 000 строк. Связанные примеры разделены по семействам между обучением и проверкой. У синтетики ограничено разнообразие ситуаций, а автоматическая разметка может ошибаться.

Отдельная проблема обнаружилась у URL-модели. Архивный набор PhiUSIIL [4] отличается от адресов, которые пользователь вводит на сайте. В частности, обычные ссылки с путями вызывали лишние предупреждения. В текущей версии изменена подготовка входа: модель получает схему и имя узла, а полный адрес остается для объяснений и проверок структуры. Это уменьшило ложные срабатывания в контрольном наборе, но снизило полноту на архивных данных.

Для итогового предупреждения я выбрал правила: по ним можно показать, какие признаки привели к результату. Статистика суммы отмечает отклонение от личной истории.

При выборе порогов важнее не пропустить подозрительные признаки. Лишние предупреждения тоже мешают, поэтому нужно разбирать оба вида ошибок. Для дообучения планируется собирать примеры проверок и отзывы с отдельного согласия пользователей, затем проверять и размечать эти данные.

Аудиоввод оказался слишком медленным: в локальной Linux-эмуляции обработка минутной записи занимала несколько минут. Значительную часть времени требовало разделение голосов. Поэтому аудио заменено проверкой QR-кодов.

Приобретенные навыки

Освоенные формы и сессии Django пригодятся мне в следующих веб-проектах.

В машинном обучении я работал с многометочной классификацией, разметкой, разбиением связанных примеров и порогами.

Также я освоил автоматические тесты, фиксацию зависимостей, сборку контейнеров и размещение приложения с базой данных.

Альтернативные пути

Я бы раньше определил, какие данные нужны для каждой проверки и какой результат считать приемлемым. Небольшой независимый набор реальных примеров помог бы обнаружить ограничения до усложнения моделей и интерфейса.

Медиаобработку также стоило проверить в начале работы: сначала измерить время и ошибки распознавания, затем включать ее в обязательный объем. Это позволило бы раньше отказаться от аудиосценария. Проверку понятности предупреждений представителями аудитории следовало начать параллельно с прототипом; эта часть еще требует завершения.

Дальнейшее развитие

Для следующей версии нужны более разнообразные русскоязычные примеры с проверенной разметкой. На них можно заново оценить модели и подобрать пороги.

Также можно улучшить распознавание переписок разных мессенджеров, поддержку банковских выписок и удобство обозначения получателей. Вернуть аудио можно после ускорения обработки и проверки качества распознавания.

В перспективе возможна интеграция с банком: с согласия пользователя учитывать более полную историю операций и профиль для предупреждений о подозрительных переводах. Для этого потребуются партнерство с банком и согласованный доступ к данным.

Источники

1. Bitdefender Scamio. https://www.bitdefender.com/en-us/consumer/scamio

2. Norton Scam Protection. https://support.norton.com/sp/en/us/home/current/solutions/v20250828202647758

3. VirusTotal. https://docs.virustotal.com/docs/how-it-works

4. PhiUSIIL Phishing URL Dataset. https://archive.ics.uci.edu/dataset/967/phiusiil+phishing+url+dataset